

BENCHMARK

Scoring de risque pour les facilités de paiement en assurance

Plateforme d'aide à la décision pour l'octroi de facilités de paiement échelonné/différé aux clients d'assurance

Phase de recherche 1 — Compréhension du problème et benchmark

Préparé par : Elaa

1. Résumé exécutif

La disparition progressive des chèques en Tunisie prive les agents d'assurance d'un moyen traditionnel d'accorder des facilités de paiement (échelonné ou différé). L'entreprise a donc besoin d'un outil **data-driven** attribuant à chaque client un score de risque et recommandant : accorder, vérifier, ou refuser la facilité.

Ce document synthétise la première phase du projet : un benchmark des pratiques data/ML pour les décisions de paiement et de risque de crédit, dans l'assurance et dans des domaines proches (scoring crédit, BNPL, assurance-crédit, propension à payer).

Cinq conclusions principales :

- Le problème se rapproche davantage d'un score de probabilité de défaut (crédit) que d'un score de tarification assurance classique.
- Les pratiques du secteur combinent systématiquement un score statistique/ML avec des règles métier explicites — cohérent avec le schéma Faible / Moyen / Élevé déjà envisagé.
- La régression logistique sur variables transformées WOE reste la référence interprétable ; le gradient boosting (XGBoost, Random Forest) sert de référence de performance.
- En l'absence probable d'historique bancaire externe complet en Tunisie, la littérature pertinente est celle du scoring "alternative data" / dossiers minces, basée sur les données comportementales internes.
- Deux limites à anticiper dès le départ : le biais de sélection (reject inference) et l'explicabilité des refus.

2. Contexte métier et objectifs

2.1 Problème métier

Les agents utilisaient les chèques post-datés pour offrir de la flexibilité de paiement. Leur disparition supprime ce repère objectif, forçant des décisions au cas par cas sans cadre de risque cohérent. L'entreprise souhaite un outil produisant un score, une catégorie de risque, et une recommandation à l'agent.

2.2 Objectifs de cette phase

- Comprendre comment des organisations comparables (assureurs, prêteurs, fintechs) structurent des décisions similaires.
- Identifier données, variables, modèles et méthodes d'évaluation standards.
- Identifier les limites documentées dans la littérature à anticiper.
- Positionner le projet et ses écarts (pas de chèques, données bureau externes limitées, données propres à l'assurance).

3. Méthodologie du benchmark

Le benchmark n'est pas un classement de scores de modèles, mais une étude structurée du paysage existant, réalisée avant toute modélisation, afin de justifier les choix futurs (définition de la cible, variables, famille de modèle, métriques, seuils) sur des bases établies plutôt qu'arbitraires.

- Pratiques du secteur : assureurs, assurance-crédit, plateformes BNPL.
- Littérature académique : scoring crédit, prédiction de défaut, scoring alternatif.
- Analogues transverses : propension à payer, prédiction de paiement de factures — structurellement proches bien que non qualifiés "scoring de facilité d'assurance".

4. Positionnement du projet

Ce projet est mieux défini comme un problème de prédiction de remboursement/défaut plutôt que de tarification de prime.

Paradigme	Ce qu'il prédit	Données typiques	Pertinence pour ce projet
Score assurance basé sur le crédit (tarification)	Probabilité de sinistres futurs	Données bureau crédit + historique sinistres	Proche conceptuellement, mais prédit le risque de sinistre, pas le comportement de paiement
Scoring crédit consommateur (PD / scorecards)	Probabilité de défaut sur une obligation de crédit	Données bureau, données de demande, historique de remboursement	Meilleure correspondance structurelle : un problème de PD posé dans une compagnie d'assurance
Moteurs de risque BNPL(buy now pay later)	Probabilité de remboursement à temps d'une transaction différée	Historique transactionnel, attributs client	Analogie opérationnel le plus proche du projet
Modèles de propension à payer	Probabilité qu'un client paie une obligation existante (3 niveaux)	Historique de facturation et de contact	Correspond directement au schéma Faible/Moyen/Élevé envisagé

5. Pratiques du secteur

5.1 Score assurance basé sur le crédit (US / UK)

Les assureurs combinent le score avec d'autres facteurs (relevés véhicules, sinistres, inspections) ; la plupart des régulateurs américains interdisent qu'il soit le seul critère d'une décision défavorable.

→ *Principe à reprendre : le score est un input parmi d'autres, jamais l'unique décideur.*

5.2 Systèmes hybrides à base de règles

MetLife utilise un système à base de règles classant les clients par catégories de risque sans calculer de score numérique unique — un système expert basé sur la logique métier.

→ *Alternative légitime, utile en première phase de déploiement quand le volume de données est encore limité.*

5.3 Assurance-crédit et prédiction de paiement de factures

Un système documenté en assurance-crédit prédit la probabilité de paiement à temps d'une facture et l'utilise pour fixer une prime ; le modèle est mis à jour selon les résultats observés. Structure très proche de l'objectif de ce projet.

5.4 Moteurs de risque BNPL / e-commerce

Les plateformes BNPL décident en temps réel, combinant un score ML avec des règles de risque explicites — l'analogie opérationnel documenté le plus proche du workflow envisagé.

5.5 Modèles de propension à payer

Des fournisseurs (ex : utilities) classent les clients en trois groupes (paiera / ne paiera pas / incertain) afin de concentrer le suivi manuel coûteux sur le groupe incertain — précédent direct pour traiter la catégorie "Moyen" comme un mécanisme d'efficacité délibéré.

6. Littérature académique et technique

6.1 Approches de modélisation

Famille de modèle	Rôle typique	Forces rapportées	Limites rapportées
Régression logistique sur WOE ("scorecard")	Référence standard, souvent modèle en production	Très interprétable ; se traduit en système de points ; bien acceptée par régulateurs	Suppose des relations linéaires après binning ; plafond de pouvoir prédictif
Random Forest	Référence ML courante	Gère non-linéarités et interactions ; robuste aux valeurs aberrantes	Moins interprétable ; modèle plus lourd à maintenir
Gradient Boosting / XGBoost	Référence ML de performance	Égale ou dépasse souvent les autres méthodes ML sur données tabulaires	Réglage plus complexe ; explicabilité nécessite un outillage additionnel (SHAP)
Réseaux de neurones	Exploré mais débattu pour données tabulaires	Modélise des interactions complexes ; utile sur très grands volumes	Bénéfice marginal débattu face au gradient boosting sur données de taille modeste

Le choix n'est pas qu'une question de précision : les systèmes de scoring en production privilégient le scorecard logistique/WOE car ses coefficients se traduisent en système de points transparent — l'interprétabilité est une exigence de premier ordre.

6.2 Données alternatives et scoring "dossier mince"

Sous-domaine le plus pertinent pour le contexte tunisien : en l'absence de dossier crédit centralisé et profond, des prêteurs télécoms/fintech ont construit des scores alternatifs à partir de données comportementales (ex. usage téléphonique), montrant un signal prédictif exploitable même sans historique de crédit traditionnel. Combiner données alternatives et données traditionnelles améliore la performance (AUC) plutôt que de remplacer les secondes.

→ *Stratégie de données la plus réaliste pour ce projet : modéliser principalement à partir des données internes (police, paiement, sinistres), en traitant tout signal comportemental interne comme l'équivalent tunisien des "données alternatives".*

6.3 Métriques d'évaluation utilisées

Métrique	Ce qu'elle mesure	Pourquoi elle est utilisée
Coefficient de Gini ($=2 \times \text{AUC} - 1$)	Pouvoir de discrimination global entre bons et mauvais clients	Résumé le plus utilisé de la qualité d'un scorecard
AUC / courbe ROC	Probabilité qu'un défaillant soit classé plus risqué qu'un non-défaillant	Métrique standard ; base du Gini
Statistique de Kolmogorov-Smirnov (KS)	Séparation maximale entre distributions bons/mauvais clients	Largement rapportée aux côtés du Gini
Lift / taux de capture	Part des mauvais clients réels capturés dans le X% le plus risqué	Répond à une question opérationnelle directe de priorisation
Métriques métier / coût	Coût attendu des faux accords vs faux refus	Relie la performance du modèle à la décision métier réelle

7. Données et variables

7.1 Familles de variables courantes

- Contrat / police : ligne de produit, montant de prime, fréquence de paiement, ancienneté, type de couverture.

- Historique de paiement : retards passés, nombre de relances, défauts d'échéance antérieurs, délais de paiement.
- Profil client : âge, profession, région, ancienneté client, nombre de polices détenues.
- Comportemental / interaction : canal de vente, fréquence de sinistres, historique de réclamation/contact.
- Données externes / alternatives : tout signal hors des systèmes internes, utilisé avec prudence selon le contexte légal tunisien.

7.2 Écart de disponibilité des données

La littérature suppose, dans la plupart des cas occidentaux, un fichier bureau de crédit externe. C'est l'écart central de ce projet : le point de départ réaliste est une modélisation uniquement sur données internes, à documenter explicitement au superviseur comme choix de cadrage plutôt que comme oubli.

8. Règles métier combinées au Machine Learning

Constat récurrent dans tous les exemples du secteur : le score n'est jamais la décision finale — il est combiné à des règles métier, seuils ou revue humaine.

- Le schéma Faible/Moyen/Élevé déjà envisagé est cohérent avec la pratique du secteur ; la catégorie Moyen doit être conçue comme un état de "vérification" déclenché par règle.
- Certaines règles fortes (litige de sinistre ouvert, client sans historique) peuvent légitimement contourner le score — à définir dès la phase de cadrage.

9. Défis et limites

9.1 Biais de sélection (reject inference)

Les scorecards ne sont entraînés que sur les clients dont l'issue est connue (déjà accordés). Les clients qui auraient été refusés n'ont pas d'issue observée — biais bien documenté à discuter explicitement avec le superviseur.

9.2 Rareté des données ("dossiers minces")

De nombreux clients manqueront d'historique financier externe profond, en particulier avec la disparition des chèques. À planifier comme contrainte de conception dès le départ.

9.3 Explicabilité et décisions défavorables

Tout outil pouvant mener à un refus doit pouvoir expliquer, au moins à haut niveau, pourquoi un client reçoit tel score — pour la confiance de l'agent et la communication au client. Cela favorise un modèle interprétable (scorecard WOE/logistique) ou un modèle complexe assorti d'une couche d'explication (ex. SHAP).

9.4 Équité et considérations réglementaires

Des études réglementaires (ex. FTC aux États-Unis) montrent que les scores basés sur le crédit prédisent bien le risque mais révèlent aussi des disparités entre groupes ethniques — précision et équité sont deux questions distinctes à examiner toutes les deux. Le projet doit pouvoir montrer quelles variables pilotent le score et confirmer l'absence de proxy pour des caractéristiques protégées.

9.5 Dérive du modèle ("model drift")

Le comportement client et le contexte macroéconomique évoluent ; un plan de suivi et de recalibrage périodique doit faire partie des considérations de déploiement.

10. Analyse des écarts et positionnement du projet

Dimension	Cas type littérature/secteur	Contexte de ce projet	Implication
Source de données principale	Fichier bureau de crédit externe	Données internes assurance uniquement (probable)	Adopter l'approche données alternatives / dossier mince

Type de décision	Ajustement tarifaire ou approbation de crédit	Accorder / vérifier / refuser une facilité sur une prime existante	Plus proche du BNPL et de la propension à payer que de la tarification assurance
Étiquettes historiques	Inclut souvent issues acceptées et refusées	Probablement issues des seuls clients déjà (informellement) approuvés	Le biais de sélection doit être traité explicitement lors de la définition de la cible
Contexte de déploiement	Scoring par lot ou souscription centralisée	Consultation en temps réel/quasi réel par un agent via un ID client	Favorise un modèle léger et rapide (scorecard interprétable ou arbre optimisé)

11. Références

- [1] NAIC. "Credit-Based Insurance Scores." content.naic.org
- [2] TransUnion. "Credit-Based Insurance Scores FAQs." transunion.com
- [3] Wikipédia. "Insurance score."
- [4] Federal Trade Commission. "Credit-Based Insurance Scores: Impacts on Consumers of Automobile Insurance."
- [5] FICO. "Credit Scores vs. Insurance Scores."
- [6] Kaushik et al. (2022). Int. J. Environ. Res. Public Health. DOI: 10.3390/ijerph19137898
- [7] Xu, Lu, Xie (2021). Scientific Reports. DOI: 10.1038/s41598-021-98361-6
- [8] Cristescu, Giordano (2025). arXiv:2506.19789
- [9] Björkegren, Grissen. arXiv:1712.05840
- [10] Óskarsdóttir et al. arXiv:2002.09931
- [11] Guttman-Kenney, Firth, Gathergood. arXiv:2201.01758
- [12] US Patent 11,068,947
- [13] US Patent 11,373,161
- [14] "Propensity-to-Pay: Machine Learning for Estimating Prediction Uncertainty." arXiv:2008.12065
- [15] "An Overview on the Landscape of R Packages for Credit Scoring." arXiv:2006.11835
- [16] Kozodoi et al. arXiv:1909.06108
- [17] "Machine learning techniques in joint default assessment." arXiv:2205.01524