

DOCUMENTATION DE NETTOYAGE DES DONNÉES

Fichiers client_pm et client_pp — première extraction réelle

Chaque décision de nettoyage ci-dessous est documentée avec sa justification et les chiffres à l'appui

Elaa Benabdallah — Juillet 2026

1. Objectif de ce document

Ce document trace, décision par décision, ce qui a été fait pour nettoyer et préparer les deux extractions réelles reçues (client_pm et client_pp), et pourquoi.

Le script complet (clean_client_data.py) applique ces transformations de façon reproductible ; ce document en explique le raisonnement métier.

2. Aperçu des fichiers reçus

Fichier	Lignes brutes	Colonnes brutes	Description
client_pm	20 389	23	Clients personnes morales (entreprises)
client_pp	137 643	18	Clients personnes physiques (particuliers)

Ces deux fichiers sont des extractions de type "fiche client" (profil, produit, agent, ancienneté). Ils ne contiennent ni historique de sinistres, ni montant de prime distinct du capital assuré, ni historique explicite de facilités de paiement passées — voir Section 5.

3. Problèmes de qualité détectés et décisions de nettoyage

3.1 Doublons de client_id — conflit entre deux colonnes d'agent

client_pm contenait 20 389 lignes pour seulement 14 620 client_id uniques ; client_pp, 137 643 lignes pour 125 618 identifiants uniques. En examinant les doublons, la cause est un conflit entre deux colonnes (code_agent et CodeAgent) qui ne concordent pas sur 723 clients (PM) et 3 087 clients (PP) — signature typique d'une jointure ayant multiplié des lignes plutôt qu'un vrai doublon métier.

Décision : une ligne par client_id est conservée ; les deux codes agent sont consolidés dans agent_code_clean, et un indicateur agent_code_conflict = Vrai est ajouté pour les clients concernés, plutôt que de choisir un code au hasard et perdre l'anomalie.

3.2 Colonnes entièrement vides

Six colonnes étaient vides à 100% dans au moins un des deux fichiers : segment_anciennete_client, email, tel, segment_age, segment_profession, niveau_revenu_estimé. Elles ont été supprimées — aucune information n'y était présente.

3.3 Redondance statut_client / fidelite_client

Ces deux colonnes portaient la même information : chaque client "Inactif" dans l'une l'était aussi dans l'autre, et "Actif" se décomposait simplement en paliers de fidélité (Loyal, Établi, Récent). Décision : conserver fidelite_client (plus fin) et en dériver un indicateur is_active, plus simple à utiliser en modélisation ; statut_client est supprimée.

3.4 Ancienneté client peu fiable

Pour client_pm, anciennete_annees affichait 0 pour 51% des lignes et exactement 6 pour 24% — une distribution trop groupée pour refléter une vraie ancienneté. La colonne anciennete_entreprise (calculée

à partir de la date de création) est bien plus détaillée (86 valeurs distinctes) et a été conservée à sa place ; anciennete_annees a été supprimée pour PM.

Pour client_pp, la même colonne va jusqu'à 184 ans (impossible) — les valeurs supérieures à 70 ans ont été mises à vide (anciennete_annees_capped) plutôt que d'inventer une valeur de remplacement.

3.5 Dates de création impossibles (PM)

5 entreprises affichaient une date de création dans le futur (jusqu'à 2028). Ces dates ont été mises à vide plutôt que devinées.

3.6 Âges implausibles (PP)

245 clients affichaient un âge inférieur à 16 ans, et 4 389 un âge supérieur à 100 ans (jusqu'à 126). Ces valeurs ont été mises à vide (age_capped) plutôt que conservées telles quelles ou remplacées par une estimation arbitraire.

3.7 Format et valeurs extrêmes du DMP

Le DMP (délai moyen de paiement, en jours) était stocké en texte avec un format français (virgule décimale, ex. "365,00"). Il a été converti en nombre (dmp_days). Les valeurs extrêmes (jusqu'à 1 462 jours pour PM, 2 128 pour PP) ont été plafonnées au 99e percentile plutôt que supprimées, car elles restent plausibles (clients très défaillants) mais déformeraient les échelles si laissées telles quelles.

Le DMP est manquant pour 4 335 clients PM (29,6%) et 21 703 clients PP (17,3%) — probablement des clients trop récents pour avoir un historique de paiement observable. Ces lignes ne sont volontairement pas complétées (voir Section 4).

3.8 Champ produit multi-valeurs

Le champ produit contient parfois plusieurs produits séparés par des virgules (jusqu'à 15 produits pour un même client). Il a été décomposé en nb_produits (nombre de produits détenus, moyenne ≈1,29) et produit_principal (premier produit listé), pour être exploitable en modélisation ; le champ brut est conservé également.

3.9 Chevauchement entre les deux fichiers

91 client_id apparaissent à la fois dans client_pm et client_pp — anormal, une entreprise et un particulier ne devraient pas partager un identifiant. Ce point est signalé pour vérification avec le superviseur ou l'IT ; aucune ligne n'a été supprimée unilatéralement, faute de savoir laquelle des deux est la source correcte.

3.10 Transformation additionnelle : capitaux fortement asymétriques

Capitaux_Totaux (PM) et Capitaux_Totale (PP) sont très asymétriques (médiane 100 000 DT, maximum 322 millions pour PM). Une version log-transformée (capitaux_log) a été ajoutée en complément de la valeur brute, sans la remplacer.

4. Variable cible — dérivée du DMP réel, non inventée

Aucune colonne "défaut" n'existe dans les fichiers reçus. La variable cible provisoire (target_default_proxy) est dérivée du DMP réel :

target_default_proxy = 1 si dmp_days > 30 jours, sinon 0 — reprenant l'Option B ("modérée") du benchmark.

Les clients sans DMP observable (pas encore d'historique de paiement) reçoivent target_default_proxy = vide et sont exclus de tout entraînement supervisé — leur attribuer une étiquette inventée reviendrait à fabriquer le résultat que le modèle est censé prédire.

	Clients étiquetés	Défaut (1)	Non-défaut (0)	Taux de défaut	Non étiquetés (DMP manquant)
client_pm	10 285	6 956	3 329	67,6%	4 335
client_pp	103 915	44 678	59 237	43,0%	21 703

Tableau — Distribution de la variable cible provisoire, par segment.

⚠ le taux de "défaut" obtenu pour les entreprises (67,6%) est nettement plus élevé que pour les particuliers (43,0%) avec le même seuil de 30 jours. C'est probablement le signe que 30 jours n'est pas le bon seuil pour les clients PM, dont les délais de paiement B2B usuels (30 à 60 jours nets) sont souvent plus longs par nature, sans que cela reflète un vrai risque. Le seuil pour PM devra très probablement être revu à la hausse avant toute utilisation réelle.

5. Ce qui n'a pas été fabriqué, et pourquoi

Ces fichiers ne contiennent aucune donnée de sinistres, aucun montant de prime distinct du capital assuré, et aucun historique explicite de facilités de paiement passées (accordées ou refusées).

Décision : ces variables ne sont PAS simulées ou inventées pour ces clients réels. Attribuer des valeurs fictives de sinistres ou de primes à des identifiants clients réels créerait des profils de risque fabriqués pour de vraies personnes/entreprises — un risque différent et plus sérieux que le jeu de données 100% synthétique déjà construit plus tôt dans ce projet, qui lui ne concerne aucun client réel.

À la place : ces variables manquantes sont documentées comme un vrai manque de données (Section 2), à demander comme extraction complémentaire (système de sinistres, système de facturation), plutôt que comblées artificiellement.

Si le superviseur souhaite spécifiquement tester une hypothèse nécessitant une de ces variables avant d'obtenir la vraie extraction, la bonne pratique reste d'ajouter une colonne clairement nommée et signalée comme synthétique (ex. claims_count_SYNTHETIC), sur une copie de travail, jamais utilisée pour noter un vrai client.

6. Colonnes disponibles après nettoyage

client_pm (14 620 lignes, 23 colonnes)

client_id, raison_sociale, date_creation_entreprise, anciennete_entreprise, Ville, region_entreprise, activite_principale, segment_secteur, produit, segment_produit, segment_contact, Capitaux_Totaux, segment_taille_entreprise, ClientType, fidelite_client, agent_code_clean, agent_code_conflict, is_active, dmp_days, nb_produits, produit_principal, capitaux_log, target_default_proxy.

client_pp (125 618 lignes, 22 colonnes)

client_id, nom_prenom, age, profession, ville, region, produit, segment_produit, Capitaux_Totale, ClientType, fidelite_client, anciennete_annees, agent_code_clean, agent_code_conflict, is_active, anciennete_annees_capped, age_capped, dmp_days, nb_produits, produit_principal, capitaux_log, target_default_proxy.

7. Limites et points à valider

- Le seuil de 30 jours pour la variable cible doit être revalidé, en particulier pour les clients PM (voir Section 4).
- Le chevauchement de 91 client_id entre PM et PP doit être vérifié — source de données ou erreur de jointure ?
- Les variables de sinistres et de prime restent manquantes — à demander comme extraction complémentaire.
- Le DMP mesure un comportement de paiement général, pas spécifiquement lié à une facilité de paiement accordée — bonne proxy disponible, mais pas une mesure exacte de l'objectif final du projet.
- Aucune trace de clients refusés pour une facilité n'existe dans ces fichiers — le biais de sélection (reject inference) identifié dans le benchmark reste entier.

8. Fichiers livrés

- clean_client_data.py — script de nettoyage complet et reproductible.
- client_pm_clean.csv / client_pp_clean.csv — données nettoyées, prêtes pour l'analyse exploratoire.
- cleaning_log.json — journal détaillé de chaque transformation (avant/après, chiffres exacts).