

NOTE — LIMITES DES DONNÉES DISPONIBLES

Constat

L'extraction de données reçue (client_pm et client_pp) couvre le profil client, le produit détenu, l'agent, l'ancienneté, et un indicateur de délai de paiement (DMP). Elle ne contient en revanche aucune donnée de sinistres, aucun montant de prime distinct du capital assuré, et aucun historique explicite de facilités de paiement passées (accordées ou refusées). Ces variables sont pourtant identifiées comme importantes dans le benchmark initial du projet.

Pourquoi ne pas générer ces variables artificiellement ?

Une piste envisagée était d'utiliser un modèle génératif pour créer des valeurs plausibles pour ces variables manquantes. Après analyse, cette approche n'est pas retenue, pour trois raisons :

- Un modèle génératif ne peut apprendre que des relations réellement présentes dans les données. Si une variable n'a jamais été observée, il n'existe aucune relation à apprendre — la valeur générée serait une hypothèse déguisée en résultat statistique, pas une inférence réelle.
- Risque de circularité : si la variable générée est même indirectement influencée par la définition de la cible, le modèle apprendrait une relation que nous aurions nous-mêmes créée — donnant de bons résultats apparents mais non valables.
- Inutilisable en production : au moment de noter un vrai client, il faudrait recalculer cette même valeur inventée — ce qui est impossible pour une variable qui n'a jamais été mesurée.

Approche recommandée : un modèle v1 sur données réelles uniquement

Plutôt que de combler artificiellement ce manque, la recommandation est de construire une première version du modèle sur les seules variables réelles disponibles : profil client, produit, ancienneté, agent, et une variable cible dérivée du DMP réel (délai de paiement observé). Ces variables ont déjà montré un signal prédictif réel lors de l'analyse exploratoire.

Ce modèle v1 sera nécessairement plus limité qu'un modèle idéal, mais il reste construit sur des données réelles et vérifiables — et donc défendable, contrairement à un modèle enrichi de variables inventées.

Ce qu'il faudrait pour aller plus loin

Pour un modèle plus complet, les données suivantes restent à demander en complément, si elles existent dans d'autres systèmes de l'entreprise :

- Historique des sinistres (nombre, montants, litiges)
- Montant de prime distinct du capital assuré
- Historique des facilités de paiement passées, y compris les refus (essentiel pour traiter le biais de sélection déjà identifié dans le benchmark)

Conclusion : le manque de données est une limite réelle et documentée, pas un problème à masquer par de la donnée synthétique. Le modèle v1 sur données réelles constitue une base solide et honnête pour avancer, en attendant une éventuelle extraction complémentaire.