

SCORING DE RISQUE — FACILITÉS DE PAIEMENT

Rapport d'analyse exploratoire des données (EDA) — Données réelles

Clients Personnes Morales (PM) et Personnes Physiques (PP)

Ce rapport présente la première analyse exploratoire réalisée sur les données réelles de l'entreprise (extractions client_pm et client_pp), faisant suite à la phase d'EDA "à blanc" menée précédemment sur un jeu de données synthétique. Les chiffres et relations présentés ici reflètent désormais le vrai portefeuille client, après nettoyage documenté et construction d'une variable cible validée.

Elaa Benabdallah — Juillet 2026

1. Contexte et objectif de cette phase

Ce document fait suite au rapport d'EDA "à blanc" réalisé sur données synthétiques. Les données réelles de l'entreprise ayant été reçues (extractions client_pm et client_pp), cette analyse remplace désormais les résultats provisoires par les résultats réels, conformément à ce qui était annoncé dans le rapport précédent.

L'objectif reste inchangé : modéliser la probabilité de défaut sur facilité de paiement (approche "propension à payer") à l'aide d'une régression logistique sur variables WOE (scorecard) et d'un modèle XGBoost servant de benchmark de comparaison. Cette EDA vise à : (1) documenter la qualité et le nettoyage des données réelles, (2) finaliser et justifier la variable cible, (3) identifier les variables les plus discriminantes vis-à-vis du défaut, et (4) orienter les choix de binning/WOE pour la phase de modélisation.

Les deux populations (PM et PP) sont analysées séparément dans ce rapport, leurs variables disponibles étant différentes.

2. Aperçu des données reçues

Fichier	Lignes brutes	Lignes après nettoyage	Colonnes finales	Description
client_pm	20 389	14 620	24	Clients personnes morales (entreprises)
client_pp	137 643	125 618	23	Clients personnes physiques (particuliers)

Ces fichiers sont des extractions "fiche client" (profil, produit, agent, ancienneté, délai moyen de paiement). Ils ne contiennent ni historique de sinistres, ni montant de prime distinct du capital assuré, ni historique explicite de facilités de paiement passées — cette limite reste documentée et n'a pas été comblée artificiellement (voir Section 8).

3. Qualité des données et nettoyage effectué

Le détail complet de chaque décision de nettoyage est documenté dans Documentation_Nettoyage_Donnees_Reelles.docx et dans cleaning_log.json. Résumé des points principaux :

- Doublons de client_id causés par un conflit entre deux colonnes d'agent (723 clients PM, 3 087 PP concernés) — consolidés plutôt que supprimés au hasard.
- 6 colonnes entièrement vides supprimées (email, tel, segment_age, etc.).
- Redondance statut_client / fidelite_client résolue — fidelite_client conservée, indicateur is_active dérivé.
- ancienneté_années jugée peu fiable (distribution trop groupée) — remplacée par ancienneté_entreprise (PM) ou plafonnée (PP, valeurs > 70 ans mises à vide).
- 5 dates de création d'entreprise dans le futur mises à vide (PM) ; 245 âges < 16 ans et 4 389 âges > 100 ans mis à vide (PP).
- DMP converti en jours (dmp_days), plafonné au 99^e percentile (492 jours PM, 354 jours PP) pour limiter l'effet des valeurs extrêmes.
- Champ produit multi-valeurs décomposé en nb_produits et produit_principal.
- 91 client_id apparaissant à la fois dans PM et PP — signalés pour vérification, non modifiés.

4. Variable cible — construction et choix du seuil

Aucune colonne "défaut" n'existe dans les données reçues. La variable cible est dérivée du DMP (délai moyen de paiement, en jours), la mesure de comportement de paiement la plus proche de l'objectif du projet disponible dans ces extractions.

Le seuil a été choisi par analyse comparative plutôt qu'arbitrairement : un premier seuil de 30 jours (utilisé dans le rehearsal synthétique) donnait un taux de "défaut" de 67,6 % pour les entreprises contre 43,0 % pour les particuliers — un résultat implausible, une définition de défaut devant identifier une minorité à risque, pas une majorité du portefeuille.

Seuil (jours)	Taux de défaut — PM	Taux de défaut — PP
30	67,6%	43,0%
45	56,6%	29,7%
60	47,9%	21,7%
90 (retenu)	35,7%	12,8%
120	26,1%	8,2%

Tableau 1 — Taux de défaut obtenu selon le seuil testé, par segment.

Le seuil de 90 jours (DPD90) est retenu : c'est la définition standard et internationalement reconnue du défaut en risque de crédit (Bâle II/III, IFRS 9), et non un choix arbitraire. Le taux obtenu à ce seuil est plausible pour les deux segments (12,8% pour les particuliers, une base de risque crédit typique ; 35,7% pour les entreprises, plus élevé mais cohérent avec des cycles de paiement B2B structurellement plus longs).

Une variable secondaire à 3 paliers (Faible / Moyen / Élevé) est également construite à partir des seuils de 30 et 90 jours, reprenant directement la structure Low/Medium/High envisagée depuis le début du projet :

Segment	Faible (≤30j)	Moyen (30-90j)	Élevé (>90j)
client_pm	32,4%	31,9%	35,7%
client_pp	57,0%	30,2%	12,8%

Tableau 2 — Répartition par palier de risque, par segment.

Les clients sans DMP observable (pas encore d'historique de paiement — 4 335 PM, 21 703 PP) reçoivent une cible vide et sont exclus de toute analyse supervisée : leur attribuer une étiquette reviendrait à fabriquer le résultat que le modèle doit prédire.

5. Analyse exploratoire — Personnes Morales (PM)

Population analysée : 10 285 clients avec DMP observé (sur 14 620 après nettoyage). Taux de défaut (DPD90) = 35,7%.

5.1 Valeurs manquantes




Figure 1 (PM) — Taux de valeurs manquantes par variable.

Quatre variables présentent des valeurs manquantes notables : Ville (21,0%), activite_principale (20,9%), is_active et fidelite_client (18,7% chacune). Des taux modérés, traitables par imputation simple ou par une catégorie "Manquant" dédiée en WOE.

5.2 Distribution de la cible




Figure 2 (PM) — Répartition binaire et par palier de risque.

5.3 Variables numériques




Figure 3 (PM) — Distributions des variables numériques (*anciennete_entreprise*, *Capitaux_Totaux*, *capitaux_log*, *nb_produits*).




Figure 4 (PM) — Variables numériques par classe (défaut / non-défaut).

5.4 Variables catégorielles et Information Value




Figure 5 (PM) — Taux de défaut par catégorie, avec IV (pointillé = taux global 35,7%).

Variable	IV	Pouvoir prédictif
produit_principal	0,570	Fort
segment_produit	0,350	Fort
segment_taille_entreprise	0,182	Moyen
fidelite_client	0,178	Moyen
activite_principale	0,088	Faible
Ville	0,072	Faible
is_active	0,067	Faible
segment_ssecteur	0,065	Faible
region_entreprise	0,057	Faible

Variable	IV	Pouvoir prédictif
segment_contact	0,039	Faible
agent_code_conflict	0,001	Nul

Tableau 3 (PM) — Information Value par variable catégorielle (>0,3 fort ; 0,1-0,3 moyen ; <0,1 faible).

Le produit détenu (produit_principal, segment_produit) domine très largement les autres variables — un résultat net et directement exploitable pour le scorecard.

5.5 Matrice de corrélation

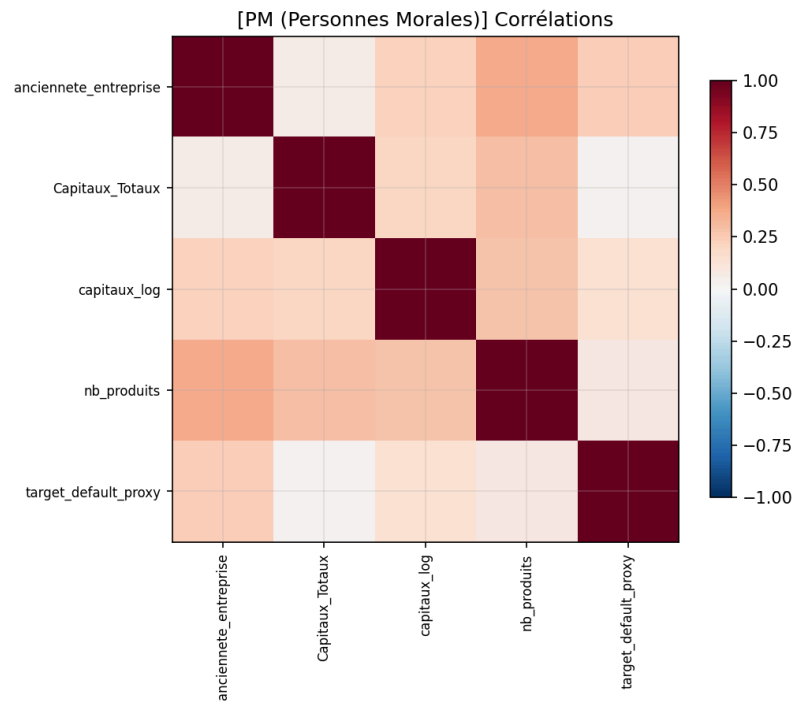


Figure 6 (PM) — Corrélations entre variables numériques et la cible.

Variable	Corrélation avec la cible
anciennete_entreprise	0,238
capitaux_log	0,139
nb_produits	0,089
Capitaux_Totaux	0,026

Tableau 4 (PM) — Corrélations numériques avec la cible.

⚠ **Résultat notable : anciennete_entreprise est corrélée POSITIVEMENT avec le défaut (0,238) — les entreprises les plus anciennes présentent un risque plus élevé, à l'inverse de l'effet "protecteur" de l'ancienneté observé sur le jeu de données synthétique. Ce point mérite d'être discuté : il peut refléter des cycles de paiement B2B structurellement plus longs pour les grandes entreprises établies, ou une composition de portefeuille particulière — une explication métier est nécessaire avant d'intégrer cette variable telle quelle dans le scorecard.**

6. Analyse exploratoire — Personnes Physiques (PP)

Population analysée : 103 915 clients avec DMP observé (sur 125 618 après nettoyage). Taux de défaut (DPD90) = 12,8%.

6.1 Valeurs manquantes




Figure 7 (PP) — Taux de valeurs manquantes par variable.

Les données PP sont globalement bien plus complètes que PM : seule ville présente un taux notable (19,3%) ; age_capped, anciennete_annees_capped et profession sont quasi complètes ($\leq 1,2\%$).

6.2 Distribution de la cible




Figure 8 (PP) — Répartition binaire et par palier de risque.

6.3 Variables numériques




Figure 9 (PP) — Distributions des variables numériques (âge, ancienneté, capitaux, nb_produits).




Figure 10 (PP) — Variables numériques par classe (défaut / non-défaut).

6.4 Variables catégorielles et Information Value




Figure 11 (PP) — Taux de défaut par catégorie, avec IV (pointillé = taux global 12,8%).

Variable	IV	Pouvoir prédictif
produit_principal	0,246	Moyen
segment_produit	0,134	Moyen
profession	0,124	Moyen
ville	0,098	Faible
region	0,079	Faible
fidelite_client	0,075	Faible
is_active	0,038	Faible
agent_code_conflict	0,000	Nul

Tableau 5 (PP) — Information Value par variable catégorielle.

6.5 Matrice de corrélation




Figure 12 (PP) — Corrélations entre variables numériques et la cible.

Variable	Corrélation avec la cible
anciennete_annees_capped	0,066
Capitaux_Totale	0,020
age_capped	0,012
nb_produits	-0,002
capitaux_log	-0,039

Tableau 6 (PP) — Corrélations numériques avec la cible.

Contrairement à PM, aucune variable numérique ne se distingue fortement ici — le signal réel, comme pour PM, réside principalement dans le produit détenu et, dans une moindre mesure, la profession.

7. Synthèse comparative et comparaison avec le rehearsal synthétique

7.1 Ce qui se confirme

- Le pipeline d'EDA construit et validé sur données synthétiques fonctionne directement sur les données réelles, sans adaptation structurelle.
- Le produit détenu (produit_principal / segment_produit) est de loin la variable la plus prédictive, pour PM comme pour PP — un signal net et immédiatement exploitable.
- Les corrélations numériques restent globalement modestes prises isolément (max 0,238) — cohérent avec l'usage d'un scorecard multivarié plutôt qu'une seule variable dominante.

7.2 Ce qui diffère du rehearsal synthétique

- Sur données synthétiques, les variables comportementales (retards passés, défauts antérieurs) dominaient — ces champs n'existant pas dans l'extraction réelle actuelle, c'est le produit détenu qui joue ce rôle de signal principal.
- L'ancienneté a un effet inverse pour PM (positif, 0,238) par rapport à l'hypothèse synthétique (protecteur)
- Un risque de redondance entre produit_principal et segment_produit est identifié (IV élevés et proches pour les deux) — à vérifier avant de les inclure tous les deux dans le modèle final, pour éviter une colinéarité inutile.

8. Limites et points à valider avant la modélisation

- Le DMP mesure un comportement de paiement général, pas spécifiquement une facilité de paiement accordée — bonne proxy disponible, mais pas une mesure exacte de l'objectif final du projet.
- Aucune trace de clients refusés pour une facilité n'existe dans ces fichiers — le biais de sélection (reject inference) identifié dans le benchmark reste entier.
- Les données de sinistres et de prime restent absentes — non comblées artificiellement (voir Note_Limites_Donnees_Approche_Recommandee.docx).
- L'effet positif de l'ancienneté sur le risque PM (Section 5.5) nécessite une explication métier avant d'être intégré tel quel au scorecard.
- Le chevauchement de 91 client_id entre PM et PP reste à vérifier .

9. Prochaines étapes

- Modélisation séparée PM et PP : scorecard logistique (WOE) et XGBoost, en excluant dmp_days des features (utilisé uniquement pour construire la cible).
- Vérifier et arbitrer la redondance produit_principal / segment_produit avant le binning WOE.
- Clarifier l'effet positif de l'ancienneté d'entreprise sur le risque PM.
- Évaluation avec séparation temporelle train/test, métriques Gini / AUC / KS, comme pour le rehearsal synthétique.