



RAPPORT DE PROJET DE STAGE

Conception d'une Plateforme de Scoring de Crédit pour les Facilités de Paiement

Cas d'application : Assurance Maghrebria

Élaboré par Elaa Benabdallah

:

Année Universitaire 2025 / 2026

Résumé

Ce rapport présente la conception d'une plateforme de scoring de crédit destinée à évaluer objectivement le risque de défaut de paiement des clients d'Assurance Maghrebria sollicitant des facilités de paiement, qu'il s'agisse d'entreprises (segment PM) ou de particuliers (segment PP). Face à une pratique historiquement fondée sur le jugement discrétionnaire des agents de souscription, l'objectif du projet est de proposer un outil d'aide à la décision statistiquement fondé, explicable et auditable.

La démarche repose sur la construction d'une cible de défaut proxy (retard de paiement supérieur à 90 jours, en cohérence avec les définitions retenues par Bâle III et IFRS 9), un travail approfondi de nettoyage et d'exploration des données réelles (14 620 entreprises et 125 618 particuliers), puis la transformation des variables explicatives par la méthode du Weight of Evidence (WoE) et de l'Information Value (IV). Deux familles de modèles ont été comparées : une régression logistique sur variables WoE (Scorecard) et un modèle d'ensemble XGBoost. Bien que XGBoost affiche un pouvoir discriminant légèrement supérieur (Gini de 0,518 contre 0,486 pour le segment PM), la Scorecard logistique a été retenue pour le déploiement en raison de sa transparence, de son explicabilité et de sa cohérence avec des principes d'auditabilité attendus dans le secteur financier et assurantiel.

Le score obtenu est ensuite calibré par percentile intra-segment plutôt que par probabilité brute, afin de neutraliser l'effet du niveau de risque moyen propre à chaque segment, et traduit en trois paliers de décision (Faible, Moyen, Élevé) validés par la croissance observée du taux de défaut réel. Un prototype opérationnel a été développé pour permettre aux agents de consulter ce score en temps réel. Le rapport se conclut par une feuille de route détaillant les perspectives d'amélioration, notamment l'enrichissement du périmètre de données via un protocole de type Sandbox pour les variables synthétiques.

Mots-clés : scoring de crédit, Weight of Evidence, Information Value, régression logistique, XGBoost, Bâle III, IFRS 9, facilités de paiement, assurance.

Table des Matières

Résumé	2
Table des Matières	3
Liste des Figures	5
Liste des Tableaux	6
Liste des Abréviations	7
Introduction Générale	8
Chapitre 1 — Contexte Général du Projet et Présentation de l'Entreprise	9
1.1 Présentation d'Assurance Maghreb	9
1.2 Le Secteur de l'Assurance en Tunisie	9
1.3 Problématique	9
1.4 Objectifs du Projet	10
1.5 Démarche Méthodologique	10
Chapitre 2 — État de l'Art et Benchmarking	12
2.1 Scoring de Crédit vs Tarification Actuarielle	12
2.2 Principes de Bâle III et IFRS 9	12
2.3 Le Weight of Evidence (WoE) et l'Information Value (IV)	13
2.4 Régression Logistique vs Modèles d'Ensemble (XGBoost / Random Forest)	13
Chapitre 3 — Traitement des Données, EDA et Feature Engineering	15
3.1 Présentation des Bases de Données	15
3.2 Nettoyage et Préparation des Données	16
3.3 Construction du Proxy de Défaut (DMP > 90 jours)	17
3.4 Analyse des Valeurs Manquantes	18
3.5 Calcul des Indicateurs WoE / IV	18
Variables numériques : corrélation avec la cible	20
3.6 Synthèse de l'Analyse Exploratoire	21
Chapitre 4 — Modélisation, Évaluation et Déploiement	23
4.1 Protocole de Modélisation	23
4.2 Comparaison des Performances (Gini / AUC)	23
4.3 Choix de la Scorecard Logistique : Justification	24
4.4 De la Probabilité au Score : Calibration par Percentile	25
4.5 Grille de Décision par Percentile	25
4.6 Explicabilité Individuelle : les Facteurs Clés	27
4.7 Recommandations Métier	28
4.8 Architecture du Prototype et Parcours de l'Agent	28
4.9 Règles Métier Inhibitoires	29
Chapitre 5 — Feuille de Route et Perspectives	31
5.1 Limites Actuelles du Projet	31
5.2 Données à Collecter à l'Avenir	31
5.3 Cadre de Gouvernance pour l'Expérimentation de Nouvelles Variables	32
Validation empirique du protocole sur données réelles	32
5.4 Vers une Mise en Production	34
Conclusion Générale	35

Bibliographie et Références	36
Annexes	37
Annexe A — Extrait du Code de Calibration par Percentile	37
Annexe B — Liste des Documents de Référence Internes	37

Liste des Figures

Figure 1 — Pipeline de traitement des données en 7 étapes

Figure 2 — Distribution de la cible de défaut par segment (PM / PP)

Figure 3 — Sensibilité du taux de défaut au seuil de DMP retenu

Figure 4 — Pouvoir prédictif des variables catégorielles — Segment PM

Figure 5 — Pouvoir prédictif des variables catégorielles — Segment PP

Figure 6 — Comparaison des performances Gini : Logistique WoE vs XGBoost

Figure 7 — Flux de calcul du score : variable brute → WoE → probabilité → score/10

Figure 8 — Validation de la grille de décision par percentile

Figure 9 — Architecture fonctionnelle du prototype de scoring

Figure 10 — Architecture fonctionnelle du prototype de scoring

Liste des Tableaux

Tableau 1 — Volumes de données par segment, avant et après nettoyage

Tableau 2 — Taux de défaut obtenu selon le seuil de retard testé, par segment

Tableau 3 — Répartition par palier de risque à 3 niveaux, par segment

Tableau 4 — Information Value (IV) des variables catégorielles — Segment PM

Tableau 5 — Information Value (IV) des variables catégorielles — Segment PP

Tableau 6 — Corrélations des variables numériques avec la cible — Segment PM

Tableau 7 — Corrélations des variables numériques avec la cible — Segment PP

Tableau 8 — Performances comparées des modèles (Gini)

Tableau 9 — Grille de décision par palier de percentile

Tableau 10 — Seuils opérationnels sur la probabilité brute, par segment

Tableau 11 — Exemple illustratif de facteurs clés — Client PP (fictif)

Tableau 12 — Grille de recommandation associée au palier de risque

Tableau 13 — Données prioritaires à collecter et leur utilité potentielle

Tableau 14 — Résultats du protocole sandbox — Segment PM vs Segment PP

Liste des Abréviations

Abréviation	Signification
PM	Personne Morale (segment entreprises)
PP	Personne Physique (segment particuliers)
DMP	Délai Moyen de Paiement
WoE	Weight of Evidence
IV	Information Value
AUC	Area Under the Curve (aire sous la courbe ROC)
Gini	Coefficient de Gini ($= 2 \times \text{AUC} - 1$)
IFRS 9	International Financial Reporting Standard n°9
Bâle III	Accords prudentiels bancaires internationaux (Basel III)
XGBoost	Extreme Gradient Boosting
CIN	Carte d'Identité Nationale
API	Application Programming Interface
EDA	Exploratory Data Analysis (analyse exploratoire des données)
ROC	Receiver Operating Characteristic

Introduction Générale

Le secteur assurantiel tunisien connaît, à l'instar du secteur bancaire, une évolution progressive vers des pratiques de gestion des risques davantage fondées sur la donnée. Parmi les activités sensibles figure l'octroi de « facilités de paiement » : la possibilité offerte à un client, particulier ou entreprise, de régler sa prime d'assurance selon un échéancier plutôt que comptant. Cette pratique commerciale, si elle facilite la fidélisation et l'accès à la couverture, expose l'assureur à un risque de crédit direct dès lors que le client ne respecte pas ses échéances.

Chez Assurance Maghrebria, cette décision d'octroi repose historiquement sur l'appréciation individuelle des agents de souscription, appuyée sur leur connaissance du client et sur des règles empiriques. Cette approche, bien que fondée sur une expertise métier réelle, présente des limites : hétérogénéité des décisions selon les agents, absence de traçabilité formelle du raisonnement, et difficulté à démontrer, en cas de contrôle ou d'audit, le caractère objectif et non discriminatoire de la décision.

L'objectif de ce projet de fin d'année est de concevoir, à partir des données réelles de gestion des contrats et des paiements, un système de scoring statistique capable d'estimer la probabilité de défaut de paiement d'un client et de traduire cette estimation en une recommandation claire à destination des agents. Une exigence centrale du projet, formulée dès son cadrage avec l'entreprise hôte, est la nécessité d'un modèle explicable : dans un secteur régulé, un modèle « boîte noire », même plus performant, est difficilement acceptable s'il ne permet pas de justifier chaque décision individuelle.

Ce rapport est structuré en cinq chapitres. Le premier chapitre présente le contexte du projet, l'entreprise hôte et la démarche méthodologique retenue. Le deuxième chapitre propose un état de l'art sur le scoring de crédit, ses fondements réglementaires et les techniques de modélisation mobilisées. Le troisième chapitre détaille le travail de préparation des données et d'ingénierie des variables, incluant la construction de la cible de défaut et les calculs de WoE/IV. Le quatrième chapitre présente la modélisation, l'évaluation comparative des approches et l'architecture du prototype déployé. Enfin, le cinquième chapitre expose la feuille de route et les perspectives d'évolution du projet.

Chapitre 1 — Contexte Général du Projet et Présentation de l'Entreprise

1.1 Présentation d'Assurance Maghrebria

Assurance Maghrebria est l'un des acteurs majeurs du marché tunisien de l'assurance, opérant sur les segments de l'assurance non-vie (automobile, risques industriels, multirisques habitation et professionnelle, transport, santé collective, etc.) ainsi que sur des segments de niche tels que l'assistance en voyage ou la responsabilité civile professionnelle. L'entreprise s'appuie sur un réseau d'agents et de courtiers répartis sur l'ensemble du territoire tunisien, qui constituent le point de contact privilégié avec une clientèle mixte composée de particuliers (personnes physiques) et d'entreprises (personnes morales).

Dans un marché caractérisé par une concurrence tarifaire forte et une pression réglementaire croissante, Assurance Maghrebria a engagé une démarche de modernisation de ses outils de pilotage du risque, incluant la digitalisation de certains processus de souscription et l'exploration de solutions de data science appliquées à la gestion du portefeuille client.

1.2 Le Secteur de l'Assurance en Tunisie

Le marché tunisien de l'assurance est régulé par le Comité Général des Assurances (CGA) et structuré autour d'une vingtaine de compagnies opérant sur les branches vie et non-vie. Ce secteur connaît une transformation progressive portée par plusieurs facteurs : la digitalisation des parcours clients, l'alignement croissant sur des référentiels prudentiels inspirés du secteur bancaire (à l'image de Solvabilité, pendant du Bâle III pour l'assurance), et une pression accrue sur la maîtrise du risque de crédit lié aux impayés de primes, particulièrement sensible dans un contexte macroéconomique marqué par des tensions sur la liquidité des ménages et des entreprises.

1.3 Problématique

La problématique centrale de ce projet peut être formulée ainsi : comment objectiver, à partir des données historiques de gestion des contrats et des paiements, la décision d'octroi d'une facilité de paiement, tout en conservant un niveau d'explicabilité et de transparence compatible avec de bonnes pratiques de gestion du risque de crédit ?

Cette problématique se décline en plusieurs questions opérationnelles :

- Quelles variables, parmi celles disponibles dans les systèmes de gestion, sont réellement prédictives du risque de défaut de paiement ?

- Comment définir une cible de défaut exploitable en l'absence de système de scoring préexistant ?
- Quel arbitrage opérer entre performance prédictive et explicabilité du modèle ?
- Comment traduire une probabilité statistique en une recommandation actionnable et compréhensible par un agent non-data scientist ?

1.4 Objectifs du Projet

Les objectifs assignés au projet sont les suivants :

- Construire, à partir des données réelles de gestion, une cible de défaut robuste, inspirée des bonnes pratiques de gestion du risque de crédit (Bâle III / IFRS 9).
- Réaliser une analyse exploratoire et un nettoyage rigoureux des bases de données Personnes Morales (PM) et Personnes Physiques (PP).
- Construire des variables explicatives pertinentes et les transformer via la méthode du Weight of Evidence (WoE).
- Développer, comparer et sélectionner un modèle de scoring explicable.
- Traduire le score du modèle en une grille de décision opérationnelle par percentile.
- Développer un prototype permettant aux agents de consulter le score en conditions réelles.

1.5 Démarche Méthodologique

La démarche adoptée suit un cycle classique de projet de data science appliqué, structuré en sept étapes principales, illustrées en Figure 1.




Figure 1 — Pipeline de traitement des données en 7 étapes

Cette démarche a été volontairement itérative : plusieurs allers-retours ont eu lieu entre les étapes de nettoyage, de construction de la cible et d'analyse exploratoire, à mesure que des incohérences ou des limites de données étaient identifiées (voir Journal des Décisions, en annexe).

Point clé

L'ensemble du travail a été mené en respectant une séparation stricte entre les variables réellement disponibles dans les systèmes de gestion et les variables hypothétiques (« _SYNTHETIC ») envisagées pour de futures évolutions, conformément au protocole Sandbox détaillé au Chapitre 5.

Chapitre 2 — État de l'Art et Benchmarking

2.1 Scoring de Crédit vs Tarification Actuarielle

Il convient, en préambule, de distinguer deux pratiques statistiques fréquemment utilisées dans le secteur assurantiel mais répondant à des objectifs différents : la tarification actuarielle et le scoring de crédit.

Critère	Tarification actuarielle	Scoring de crédit
Objectif	Estimer le coût attendu d'un sinistre pour fixer une prime	Estimer la probabilité de défaut de paiement d'un client
Variable cible	Fréquence et coût des sinistres	Défaut / non-défaut de paiement (variable binaire)
Horizon	Durée du contrat (souvent annuel)	Généralement 12 mois glissants
Cadre réglementaire de référence	Solvabilité, normes actuarielles	Bâle III, IFRS 9 (par analogie, secteur bancaire)
Techniques typiques	GLM, modèles fréquence-coût	Régression logistique WoE, arbres, ensembles

Le présent projet se situe résolument dans le champ du scoring de crédit : il ne s'agit pas d'ajuster une prime d'assurance, mais d'évaluer un risque de non-paiement, ce qui justifie l'emprunt méthodologique aux référentiels bancaires (Bâle III, IFRS 9) plutôt qu'aux seules pratiques actuarielles classiques.

2.2 Principes de Bâle III et IFRS 9

Bâle III est un ensemble d'accords prudentiels internationaux définissant, entre autres, la notion de défaut d'un débiteur. Une définition largement reprise dans la pratique consiste à considérer qu'un débiteur est en défaut lorsque ses arriérés de paiement dépassent 90 jours consécutifs sur une obligation significative. Cette définition, bien qu'initialement bancaire, constitue un référentiel opérationnel transposable à la relation entre un assureur et ses clients bénéficiant de facilités de paiement.

La norme comptable IFRS 9, applicable aux établissements financiers et de plus en plus mobilisée par analogie dans le secteur assurantiel pour le provisionnement des créances, repose sur un modèle de pertes attendues (« Expected Credit Loss ») structuré en trois catégories (Stage 1, 2, 3) selon la dégradation du risque de crédit observée depuis l'octroi. Le passage en Stage 3 (créance dépréciée) est généralement associé à un défaut avéré, dont le seuil opérationnel usuel est également fixé à 90 jours de retard.

Choix méthodologique retenu

C'est cette convergence entre Bâle III et IFRS 9 autour du seuil de 90 jours qui justifie le choix, documenté au Chapitre 3, du proxy de défaut retenu pour ce projet : DMP (Délai Moyen de Paiement) > 90 jours. Ce choix permet d'ancrer la définition de la cible sur un référentiel reconnu plutôt que sur un seuil arbitraire, renforçant ainsi la défendabilité du modèle en cas d'audit.

2.3 Le Weight of Evidence (WoE) et l'Information Value (IV)

Le Weight of Evidence est une technique de transformation de variable largement utilisée dans la construction de scorecards de crédit. Pour une modalité i d'une variable catégorielle (ou d'un intervalle d'une variable continue discrétisée), le WoE est défini par :

$$WoE(i) = \ln(\% \text{ de non-événements dans } i / \% \text{ d'événements dans } i)$$

où « événement » désigne classiquement le défaut. Un WoE positif indique que la modalité concentre proportionnellement moins de défauts que la moyenne (modalité protectrice), tandis qu'un WoE négatif indique une sur-représentation du défaut (modalité à risque).

L'Information Value agrège les WoE de toutes les modalités d'une variable pour quantifier son pouvoir prédictif global :

$$IV = \sum_i (\% \text{non-événements}(i) - \% \text{événements}(i)) \times WoE(i)$$

L'IV se lit selon une grille de référence largement admise dans la pratique du scoring :

Plage d'IV	Interprétation du pouvoir prédictif
< 0,02	Variable non prédictive
0,02 – 0,10	Pouvoir prédictif faible
0,10 – 0,30	Pouvoir prédictif moyen
0,30 – 0,50	Pouvoir prédictif fort
> 0,50	Pouvoir prédictif suspect (risque de sur-apprentissage / fuite de données)

L'intérêt principal de l'approche WoE réside dans le fait qu'elle transforme des variables catégorielles ou continues en une échelle continue et monotone par rapport au risque, directement interprétable, et qu'elle rend possible l'usage d'une simple régression logistique tout en captant des relations non linéaires grâce au binning préalable.

2.4 Régression Logistique vs Modèles d'Ensemble (XGBoost / Random Forest)

La régression logistique, appliquée sur variables encodées en WoE (on parle alors de « Scorecard logistique »), reste la référence historique du scoring de crédit. Elle présente l'avantage de produire des coefficients directement interprétables : chaque variable contribue de façon additive au score final, ce qui permet de décomposer intégralement la décision pour un client donné.

Les modèles d'ensemble, tels que Random Forest ou XGBoost (Extreme Gradient Boosting), reposent sur l'agrégation de nombreux arbres de décision. Ils captent naturellement les interactions complexes et les relations non linéaires entre variables, ce qui leur permet généralement d'atteindre un pouvoir discriminant supérieur à performance égale de préparation des données. Leur principale limite, dans un

contexte réglementé, est leur moindre explicabilité directe : bien que des techniques post-hoc (SHAP, importance de variables) permettent d'en éclairer partiellement le fonctionnement, elles ne fournissent pas une décomposition aussi simple et auditable qu'une équation logistique sur variables WoE.

Comment les coefficients sont-ils appris ?

Concrètement, l'algorithme d'estimation (maximum de vraisemblance) recherche, pour chaque variable WoE encodée, le coefficient β qui rend les probabilités prédites par le modèle aussi cohérentes que possible avec les défauts réellement observés sur l'échantillon d'entraînement. Par construction, plus une variable sépare nettement les clients en défaut des clients sains (IV élevé), plus son coefficient tendra à être important en valeur absolue. Le score final d'un client s'obtient ensuite en sommant, pour chacune de ses caractéristiques, le produit de ce coefficient par sa valeur WoE — c'est cette structure additive et transparente qui permet, au Chapitre 4, de décomposer individuellement chaque score en « facteurs clés ».

Ce compromis entre performance et explicabilité constitue l'un des fils conducteurs de ce rapport, et sera tranché de façon argumentée au Chapitre 4.

Chapitre 3 — Traitement des Données, EDA et Feature Engineering

3.1 Présentation des Bases de Données

Le projet mobilise deux bases de données distinctes, correspondant aux deux segments de clientèle d'Assurance Maghrebria bénéficiant de facilités de paiement :

- Le segment PM (Personnes Morales / entreprises), identifié par un matricule fiscal, regroupant la base de gestion des contrats entreprises.
- Le segment PP (Personnes Physiques / particuliers), identifié par un numéro de Carte d'Identité Nationale (CIN), regroupant la base de gestion des contrats particuliers.

Ces fichiers sont des extractions de type « fiche client » (profil, produit, agent, ancienneté, délai moyen de paiement). Ils ne contiennent en revanche ni historique de sinistres, ni montant de prime distinct du capital assuré, ni historique explicite de facilités de paiement passées — une limite structurelle assumée et documentée dès cette étape plutôt que comblée artificiellement.

Tableau 1 — Volumes de données par segment, avant et après nettoyage

Segment	Lignes brutes	Après nettoyage	Colonnes finales	Périmètre de modélisation*
PM (Entreprises)	20 389	14 620	24	10 285
PP (Particuliers)	137 643	125 618	23	103 915

* Le périmètre de modélisation exclut les clients pour lesquels aucun DMP (Délai Moyen de Paiement) n'est encore observable faute d'historique de paiement suffisant — 4 335 clients PM et 21 703 clients PP dans ce cas. Attribuer une étiquette de défaut à ces clients reviendrait à fabriquer la donnée que le modèle doit précisément apprendre à prédire ; ils ont donc été exclus de toute analyse supervisée, conformément au Journal des Décisions.

L'écart marqué entre les taux de défaut des deux segments (35,7 % pour les entreprises contre 12,8 % pour les particuliers) constitue un enseignement important pour la suite du projet : il justifie l'entraînement de deux modèles distincts, spécifiques à chaque segment, plutôt qu'un modèle unique, ainsi que la nécessité d'une calibration relative (par percentile) plutôt qu'absolue du score final, développée au Chapitre 4.




Figure 2 — Distribution de la cible de défaut par segment (PM / PP)

3.2 Nettoyage et Préparation des Données

Le travail de nettoyage, détaillé dans la documentation dédiée (« Documentation Nettoyage Données Réelles » et `cleaning_log.json`, en annexe), a porté notamment sur :

- Le traitement de doublons de `client_id` causés par un conflit entre deux colonnes d'agent (723 clients PM et 3 087 clients PP concernés) — consolidés plutôt que supprimés au hasard, avec conservation d'un indicateur `agent_code_conflict`.
- La suppression de 6 colonnes entièrement vides (email, téléphone, segment d'âge, etc.), sans valeur informative.
- La résolution de la redondance entre `statut_client` et `fidelite_client` : `fidelite_client` a été conservée comme variable de référence, et un indicateur binaire `is_active` en a été dérivé séparément.
- L'abandon de la variable `ancienneté_années`, jugée peu fiable (distribution anormalement groupée), au profit d'`ancienneté_entreprise` (PM) ou d'une version plafonnée pour le PP.
- La correction de valeurs manifestement erronées : 5 dates de création d'entreprise dans le futur mises à vide (PM) ; 245 âges inférieurs à 16 ans et 4 389 âges supérieurs à 100 ans mis à vide (PP).
- La conversion du DMP en jours (`dmp_days`), plafonné au 99^e percentile (492 jours pour le PM, 354 jours pour le PP) afin de limiter l'effet des valeurs extrêmes sans les supprimer.
- La décomposition du champ produit multi-valeurs en deux variables : `nb_produits` (nombre de produits souscrits) et `produit_principal` (produit historiquement le plus représentatif de la relation client).
- Le signalement (sans modification automatique) de 91 identifiants `client_id` apparaissant simultanément dans les segments PM et PP.

3.3 Construction du Proxy de Défaut (DMP > 90 jours)

Aucune colonne « défaut » n'existe dans les données reçues. La variable cible a donc été dérivée du DMP (délai moyen de paiement, en jours), la mesure de comportement de paiement la plus proche de l'objectif du projet disponible dans ces extractions.

Le seuil de retard définissant le défaut a été choisi par analyse comparative, et non arbitrairement : le tableau suivant restitue le taux de défaut obtenu pour cinq seuils candidats.

Tableau 2 — Taux de défaut obtenu selon le seuil de retard testé, par segment

Seuil (jours)	Taux de défaut — PM	Taux de défaut — PP
30	67,6 %	43,0 %
45	56,6 %	29,7 %
60	47,9 %	21,7 %
90 (retenu)	35,7 %	12,8 %
120	26,1 %	8,2 %




Figure 3 — Sensibilité du taux de défaut au seuil de DMP retenu

Un premier seuil de 30 jours, hérité du rehearsal mené sur données synthétiques, donnait un taux de défaut de 67,6 % pour les entreprises et de 43,0 % pour les particuliers — un résultat jugé implausible, une définition de défaut devant par construction identifier une minorité à risque, non la majorité du portefeuille. Le seuil de 90 jours a finalement été retenu pour deux raisons convergentes : c'est un seuil très largement utilisé comme référence méthodologique pour construire un proxy de défaut en risque de crédit (Bâle II/III, IFRS 9, cf. Chapitre 2) — sans que le projet ne relève pour autant du champ d'application réglementaire direct de ces textes, propres au secteur bancaire — et le taux obtenu à ce seuil est plausible pour les deux segments (12,8 % pour les particuliers, une base de risque crédit typique ; 35,7 % pour les entreprises, plus élevé mais cohérent avec des cycles de paiement B2B structurellement plus longs).

$$target_default_proxy = 1 \text{ si } dmp_days > 90, \text{ sinon } 0$$

Une variable secondaire à trois paliers (Faible / Moyen / Élevé) a également été construite à partir des seuils de 30 et 90 jours, reprenant la structure Low / Medium / High envisagée depuis le cadrage initial du projet :

Tableau 3 — Répartition par palier de risque à 3 niveaux, par segment

Segment	Faible (≤ 30 j)	Moyen (30-90 j)	Élevé (> 90 j)
PM (Entreprises)	32,4 %	31,9 %	35,7 %
PP (Particuliers)	57,0 %	30,2 %	12,8 %

Les limites inhérentes à cette approche proxy — absence de distinction entre défaut « volontaire » et incident ponctuel, absence de prise en compte des recouvrements partiels, et absence de toute trace des clients dont la demande de facilité aurait été refusée (biais de sélection / reject inference) — sont discutées de façon transparente dans la note dédiée (« Note Limites Données & Approche Recommandée », en annexe) et reprises au Chapitre 5.

3.4 Analyse des Valeurs Manquantes

Le segment PM présente davantage de valeurs manquantes que le segment PP. Quatre variables PM dépassent 18 % de valeurs manquantes : Ville (21,0 %), activite_principale (20,9 %), is_active et fidelite_client (18,7 % chacune) — des taux modérés, traités par une catégorie dédiée « Manquant » plutôt que par suppression ou imputation, afin de préserver l'information potentiellement contenue dans l'absence de donnée elle-même. Le segment PP est nettement plus complet : seule la variable ville présente un taux notable (19,3 %) ; age_capped, anciennete_annees_capped et profession sont quasi complètes ($\leq 1,2$ % de valeurs manquantes).

3.5 Calcul des Indicateurs WoE / IV

Chaque variable candidate a fait l'objet d'un binning (regroupement en classes pour les variables continues, ou regroupement de modalités rares pour les variables catégorielles), suivi du calcul du WoE de chaque classe et de l'IV global de la variable, selon les formules présentées au Chapitre 2.

Tableau 4 — Information Value (IV) des variables catégorielles — Segment PM

Variable	IV	Pouvoir prédictif
Produit principal	0,570	Très fort — à vérifier
Segment de produit	0,350	Fort
Taille de l'entreprise (segment)	0,182	Moyen
Fidélité client	0,178	Moyen
Activité principale	0,088	Faible
Ville	0,072	Faible
Statut actif / inactif	0,067	Faible
Secteur d'activité	0,065	Faible
Région de l'entreprise	0,057	Faible
Segment de contact	0,039	Faible
Conflit sur le code agent	0,001	Nul




Figure 4 — Pouvoir prédictif des variables catégorielles — Segment PM

Point de vigilance : une IV élevée n'est pas automatiquement un bon signal

Le Chapitre 2 (§2.3) a rappelé qu'une IV supérieure à 0,50 est habituellement considérée comme suspecte plutôt que simplement excellente, car elle peut signaler un sur-apprentissage ou, plus grave, une fuite de données (la variable encode indirectement une information dérivée de la cible elle-même). L'IV de 0,570 obtenue pour `produit_principal` doit donc être lue comme « très forte, à vérifier » et non comme un simple signal positif à prendre tel quel. Deux vérifications sont nécessaires avant intégration définitive : s'assurer que le produit détenu est bien connu au moment de l'octroi de la facilité (et non déterminé a posteriori par le comportement de paiement lui-même, ce qui constituerait une fuite de données), et arbitrer la redondance avec `segment_produit` signalée ci-dessous.

Tableau 5 — Information Value (IV) des variables catégorielles — Segment PP

Variable	IV	Pouvoir prédictif
Produit principal	0,246	Moyen
Segment de produit	0,134	Moyen
Profession	0,124	Moyen
Ville	0,098	Faible
Région	0,079	Faible
Fidélité client	0,075	Faible
Statut actif / inactif	0,038	Faible
Conflit sur le code agent	0,000	Nul




Figure 5 — Pouvoir prédictif des variables catégorielles — Segment PP

Le constat le plus net, pour les deux segments, est que le produit détenu (`produit_principal`, puis `segment_produit`) domine très largement le pouvoir prédictif de toutes les autres variables — un résultat exploitable pour la construction de la scorecard, sous réserve des vérifications mentionnées ci-dessus. Ce résultat diffère de l'hypothèse initiale posée lors du rehearsal sur données synthétiques, où des variables comportementales (retards ou défauts antérieurs) dominaient : ces champs n'existant pas dans l'extraction réelle actuelle, c'est le produit détenu qui en joue le rôle de signal principal.

Point de vigilance — risque de colinéarité

`produit_principal` et `segment_produit` affichent des IV élevés et proches sur les deux segments. Ces deux variables étant probablement fortement corrélées entre elles (le segment de produit dérivant largement du produit principal), leur inclusion simultanée dans le modèle final expose à un risque de redondance et de colinéarité inutile. Ce point, identifié dès l'EDA, doit être arbitré avant le binning WoE définitif (Chapitre 4) — par exclusion de l'une des deux variables ou par une variable combinée.

Variables numériques : corrélation avec la cible

Contrairement aux variables catégorielles, les variables numériques n'ont pas fait l'objet d'un calcul d'IV à ce stade de l'EDA, mais d'une simple analyse de corrélation avec la cible, afin d'orienter les choix de binning ultérieurs.

Tableau 6 — Corrélations des variables numériques avec la cible — Segment PM

Variable	Corrélation avec la cible
Ancienneté de l'entreprise	0,238
Capitaux totaux assurés (log)	0,139
Nombre de produits souscrits	0,089

Capitaux totaux assurés (brut)	0,026
--------------------------------	-------

Tableau 7 — Corrélations des variables numériques avec la cible — Segment PP

Variable	Corrélation avec la cible
Ancienneté (années, plafonnée)	0,066
Capitaux totaux assurés (brut)	0,020
Âge (plafonné)	0,012
Nombre de produits souscrits	−0,002
Capitaux totaux assurés (log)	−0,039

Les corrélations numériques restent globalement modestes prises isolément (0,238 au maximum, sur PM) — un résultat cohérent avec l'usage prévu d'un scorecard multivarié plutôt que d'une variable unique dominante, et contrairement au segment PM, aucune variable numérique ne se distingue fortement sur le segment PP : le signal y réside, comme pour PM, principalement dans le produit détenu et, dans une moindre mesure, la profession.

Résultat notable à expliquer avant modélisation

L'ancienneté de l'entreprise est corrélée POSITIVEMENT avec le défaut sur le segment PM (0,238) : les entreprises les plus anciennes présentent un risque plus élevé, à l'inverse de l'effet protecteur de l'ancienneté généralement supposé et observé sur le jeu de données synthétique du rehearsal. Ce résultat contre-intuitif peut refléter des cycles de paiement B2B structurellement plus longs chez les grandes entreprises établies, ou une composition particulière du portefeuille — mais une explication métier est nécessaire avant d'intégrer cette variable telle quelle dans la scorecard finale. Ce point reste ouvert et est repris comme axe de vigilance au Chapitre 5.

3.6 Synthèse de l'Analyse Exploratoire

L'analyse exploratoire complète, restituée dans le « Rapport EDA Données Réelles » (annexe), confirme que le pipeline construit et validé en amont sur données synthétiques fonctionne directement sur les données réelles, sans adaptation structurelle. Elle met cependant en évidence plusieurs écarts par rapport aux hypothèses du rehearsal synthétique, qui orientent directement les choix de modélisation du Chapitre 4 :

- Le produit détenu, absent des hypothèses initiales, s'impose comme la variable la plus discriminante des deux segments, en l'absence de variables comportementales historiques.
- L'effet de l'ancienneté d'entreprise s'inverse par rapport à l'hypothèse synthétique et nécessite une explication métier avant intégration définitive.
- Un risque de colinéarité entre `produit_principal` et `segment_produit` doit être arbitré avant le binning WoE.
- Le biais de sélection lié à l'absence de traçabilité des clients refusés (reject inference) reste entier et constitue une limite structurelle du dispositif actuel.

Chapitre 4 — Modélisation, Évaluation et Déploiement

4.1 Protocole de Modélisation

Deux modèles distincts ont été entraînés pour chaque segment (PM et PP), sur la base des variables encodées en WoE présentées au Chapitre 3 : une régression logistique (Scorecard) et un modèle XGBoost. L'évaluation a été réalisée par séparation aléatoire entre échantillons d'entraînement et de test, la performance étant mesurée par le coefficient de Gini, indicateur usuel du pouvoir discriminant d'un modèle de scoring, défini à partir de l'aire sous la courbe ROC (AUC) par la relation $Gini = 2 \times AUC - 1$.

■ Limite méthodologique assumée

L'évaluation a été conduite sur une séparation aléatoire des observations et non sur une séparation temporelle (train sur une période, test sur une période postérieure), faute de date de transaction exploitable dans les exports actuels. Cette limite, documentée dans le Journal des Décisions, constitue l'un des axes prioritaires de la feuille de route présentée au Chapitre 5.

4.2 Comparaison des Performances (Gini / AUC)

Tableau 8 — Performances comparées des modèles (Gini)

Modèle	Gini — Segment PM	Gini — Segment PP
Régression Logistique WoE (Scorecard)	0,486	0,349
XGBoost	0,518	0,448
Écart absolu	+0,032	+0,099




Figure 6 — Comparaison des performances Gini : Logistique WoE vs XGBoost

Le modèle XGBoost affiche un pouvoir discriminant supérieur sur les deux segments, l'écart étant particulièrement marqué sur le segment PP (+0,099 point de Gini). Ce résultat est cohérent avec la littérature : les modèles d'ensemble captent des interactions entre variables (par exemple entre profession, région et produit souscrit) qu'une régression logistique additive sur variables WoE ne peut représenter qu'imparfaitement.

4.3 Choix de la Scorecard Logistique : Justification

Malgré l'avantage de performance de XGBoost, la Scorecard logistique WoE a été retenue comme modèle de référence pour le déploiement en production. Cette décision, actée en accord avec l'encadrement professionnel et documentée dans le Journal des Décisions, repose sur les arguments suivants :

- **Explicabilité totale** : chaque décision individuelle peut être décomposée en la somme des contributions WoE de chaque variable, pondérées par les coefficients de la régression — une propriété qu'aucune technique post-hoc appliquée à XGBoost ne peut égaler en simplicité.
- **Auditabilité** : dans un contexte où la transparence des décisions envers l'agent et, in fine, envers le client est attendue, un modèle linéaire sur variables WoE peut être audité ligne par ligne par une tierce partie sans accès au code source du modèle.
- **Stabilité et gouvernance** : les coefficients d'une régression logistique sont plus simples à surveiller dans le temps (data drift) et à faire valider par un comité des risques que les centaines d'arbres d'un modèle XGBoost.

- Écart de performance jugé raisonnable : l'écart de Gini, bien que non négligeable sur le segment PP, ne modifie pas le classement relatif des clients de façon suffisamment significative pour justifier la perte d'explicabilité, au regard des enjeux opérationnels du cas d'usage (aide à la décision, non décision automatique).

XGBoost reste néanmoins conservé comme modèle de référence (« challenger ») à des fins de suivi de performance et de détection d'éventuelles limites de la Scorecard logistique, sans être exposé directement aux agents.

4.4 De la Probabilité au Score : Calibration par Percentile

La probabilité de défaut brute issue de la régression logistique ne peut être utilisée telle quelle pour construire un score comparable entre les deux segments, en raison de l'écart de taux de défaut moyen déjà signalé (35,7 % pour PM contre 12,8 % pour PP). Une conversion directe (par exemple $\text{score} = \text{probabilité} \times 10$) produirait un score PM structurellement plus élevé que le score PP pour un niveau de risque relatif équivalent, faussant l'interprétation par les agents.

La solution retenue consiste à calculer, pour chaque client, son rang percentile au sein de la distribution réelle des probabilités de son propre segment, puis à convertir ce percentile en un score sur 10 ($\text{score}_{10} = \text{percentile} / 10$). Un score de 8/10 signifie ainsi, dans les deux segments, « plus risqué que 80 % des clients comparables du même segment », indépendamment du niveau de risque moyen absolu du segment.




Figure 7 — Flux de calcul du score : variable brute → WoE → probabilité → score/10

4.5 Grille de Décision par Percentile

Trois paliers de décision ont été définis à partir des seuils de percentile : Faible (percentile 0 à 5, soit score 0 à 5/10), Moyen (percentile 5 à 8) et Élevé (percentile 8 à 10). Ces seuils, initialement choisis pour être proportionnellement comparables entre segments, ont ensuite été validés empiriquement en vérifiant que le taux de défaut réel observé croît bien de façon monotone d'un palier à l'autre — condition indispensable pour qu'une grille de risque soit opérationnellement pertinente.

Tableau 9 — Grille de décision par palier de percentile

Palier	Percentile / Score	Taux de défaut réel — PM	Taux de défaut réel — PP
Risque Faible	0 – 5 / 10	18,8 %	7,5 %
Risque Moyen	5 – 8 / 10	39,8 %	13,5 %
Risque Élevé	8 – 10 / 10	71,6 %	24,8 %

Validation de la grille de décision par percentile : croissance monotone du risque




Figure 8 — Validation de la grille de décision par percentile

La croissance très marquée du taux de défaut observé entre le palier Faible et le palier Élevé — de 18,8 % à 71,6 % sur le segment PM, et de 7,5 % à 24,8 % sur le segment PP — constitue la validation empirique la plus solide de la pertinence de la grille : elle démontre que la calibration par percentile ne se contente pas d'ordonner les clients de façon arbitraire, mais isole effectivement des populations à risque réel très différencié.

Un second jeu de seuils, exprimés cette fois sur la probabilité brute (et non sur le percentile), a également été conservé dans les métadonnées du modèle (`threshold_high` / `threshold_medium`), résumé dans le tableau suivant.

Tableau 10 — Seuils opérationnels sur la probabilité brute, par segment

Segment	Seuil « Risque Moyen »	Seuil « Risque Élevé »	Taux de défaut de base
PM (Entreprises)	0,08	0,12	35,7 %
PP (Particuliers)	0,09	0,14	12,8 %

i Précision importante — ces seuils ne pilotent pas l'affichage agent

Ces seuils sur la probabilité brute ne servent pas à classer le niveau de risque affiché à l'agent : c'est la grille par percentile (Tableau 8 ci-dessus) qui remplit ce rôle, précisément parce qu'un seuil sur la probabilité brute appliqué de façon identique aux deux segments reproduirait le biais initial (une majorité de clients PM classés en risque élevé du seul fait du niveau de risque moyen plus élevé du segment). Ces seuils bruts sont conservés uniquement comme paramètre technique interne du modèle, hérité de la phase de développement, et ne constituent pas une seconde grille de décision concurrente. Toute évolution future qui les mobiliserait opérationnellement devra le faire de façon clairement documentée pour éviter toute ambiguïté avec la grille percentile.

4.6 Explicabilité Individuelle : les Facteurs Clés

Au-delà de l'explicabilité globale du modèle (la structure additive de la régression logistique sur variables WoE), il est indispensable, pour un usage opérationnel par les agents, de pouvoir expliquer le score d'un client particulier. La structure du modèle le permet directement : la contribution de chaque variable i au score d'un client donné s'obtient par le produit de son coefficient de régression et de sa valeur WoE observée pour ce client :

$$\text{Contribution}(i) = \beta(i) \times \text{WoE}(i)$$

Pour un client donné, ces contributions sont calculées pour l'ensemble des variables du modèle, puis classées par valeur absolue décroissante. Les trois à quatre contributions les plus fortes — qu'elles augmentent ou réduisent le risque — sont retenues comme « Facteurs clés » et traduites en langage simple à destination de l'agent, comme illustré ci-dessous pour un client fictif du segment PP.

Tableau 11 — Exemple illustratif de facteurs clés — Client PP (fictif)

Facteur	Sens	Explication en langage simple
Produit principal	↑ Augmente le risque	Le produit détenu est historiquement associé à un niveau de risque supérieur à la moyenne des clients comparables.
Fidélité client	↓ Réduit le risque	La fidélité du client contribue favorablement à son profil de risque.
Ancienneté	↑ Augmente le risque	Cette caractéristique contribue à augmenter le niveau de risque estimé pour ce client.

i Point de rigueur essentiel

Ces facteurs clés ne constituent pas des causes du défaut, et ne doivent jamais être présentés comme telles à l'agent ou au client. Ils représentent uniquement les variables ayant le plus contribué, statistiquement, au calcul du score individuel, dans le cadre du modèle retenu. Cette distinction entre corrélation statistique et causalité doit être rappelée dans toute documentation ou formation destinée aux agents utilisateurs du prototype.

4.7 Recommandations Métier

Le score et le palier de risque ne constituent qu'une partie de la réponse fournie à l'agent : ils sont systématiquement accompagnés d'une recommandation métier, elle-même construite comme une couche de règles distincte du modèle statistique — le modèle de Machine Learning produit un score, la recommandation qui en découle relève d'un choix de gestion du risque propre à l'entreprise.

Tableau 12 — Grille de recommandation associée au palier de risque

Niveau	Résultat du modèle	Recommandation
--------	--------------------	----------------

Faible	Risque relatif faible	Accorder selon les conditions standards.
Moyen	Risque relatif intermédiaire	Vérifier certaines informations avant validation (vérification complémentaire).
Élevé	Risque relatif élevé	Ne pas accorder automatiquement ; validation supplémentaire requise.

La « vérification complémentaire » associée au palier Moyen ne désigne pas une procédure automatisée supplémentaire, mais un ensemble d'actions de contrôle à la main de l'agent ou de son responsable, par exemple :

- Vérification de la situation contractuelle actuelle du client (contrats en cours, historique récent).
- Vérification des informations administratives déclarées (cohérence des données saisies).
- Consultation d'informations récentes disponibles dans le dossier client.
- Validation par un responsable, selon la procédure interne en vigueur.

i Point de rigueur essentiel

Les recommandations constituent une couche de règles métier construite en aval du modèle. Elles ne sont pas directement apprises par le modèle de Machine Learning et peuvent évoluer indépendamment de celui-ci, en fonction de la politique de risque de l'entreprise.

4.8 Architecture du Prototype et Parcours de l'Agent

Le prototype développé permet à un agent d'obtenir, en quelques secondes, le score de risque d'un client réel, son palier, ses facteurs clés et une recommandation. Le parcours agent a été conçu en cinq étapes :

1. Sélection du type de client : Personne Physique (PP) ou Personne Morale (PM).
2. Identification du client : numéro de Carte d'Identité Nationale (CIN) pour le PP, Matricule Fiscal pour le PM.
3. Recherche de la fiche client dans la base correspondante.
4. Calcul du score par le backend (encodage WoE, régression logistique, calibration percentile).
5. Affichage du résultat à l'agent : score sur 10, niveau de risque, facteurs clés et recommandation.

Ce parcours en deux temps (sélection explicite du segment puis identification par le bon référentiel, CIN ou Matricule Fiscal) répond directement à une difficulté identifiée lors des premières démonstrations du prototype : la confusion possible entre les deux référentiels d'identification lorsque l'agent ne précisait pas au préalable le type de client recherché.

Sur le plan technique, l'architecture retenue s'appuie sur un backend applicatif qui recherche le client dans le segment sélectionné, charge ses caractéristiques réelles, applique les tables de WoE du modèle

correspondant, calcule la probabilité de défaut avec le modèle de régression logistique sérialisé, puis traduit cette probabilité en score et en palier via le module de calibration par percentile, avant de générer les facteurs clés et la recommandation associée.




Figure 9 — Architecture fonctionnelle du prototype de scoring

Cette architecture modulaire sépare clairement les données, les artefacts du modèle (tables WoE, modèle sérialisé, métadonnées de seuils) et la logique de présentation, facilitant la maintenance et l'évolution future du système sans réentraînement systématique de l'interface.

4.9 Règles Métier Inhibitoires

Indépendamment du score statistique, certaines règles métier dites « inhibitoires » ont été maintenues en amont ou en aval du scoring, afin de traiter des cas que le modèle ne peut ou ne doit pas arbitrer seul :

- Signalement systématique des identifiants clients ambigus (91 client_id présents à la fois dans les segments PM et PP), plutôt que résolution automatique silencieuse, afin de garantir la traçabilité de la décision.
- Non-substitution du score à l'appréciation de l'agent : le prototype restitue une recommandation, jamais une décision automatique bloquante.
- Exclusion explicite de toute variable protégée ou proxy direct d'une caractéristique sensible (aucune variable de ce type n'a été identifiée dans le périmètre actuel, mais le protocole de revue documenté au Chapitre 5 prévoit un contrôle systématique à chaque évolution du modèle).

Chapitre 5 — Feuille de Route et Perspectives

5.1 Limites Actuelles du Projet

Avant de présenter les perspectives d'évolution, il est nécessaire de rappeler, en toute transparence, les principales limites du dispositif actuel, déjà évoquées au fil des chapitres précédents :

- Le modèle a été évalué sur une séparation aléatoire des observations, non sur une séparation temporelle, faute de date de transaction fiable et exploitable dans les exports disponibles.
- Le proxy de défaut ($DMP > 90$ jours) mesure un comportement de paiement général et non spécifiquement une facilité de paiement accordée : une bonne proxy disponible, mais pas une mesure exacte de l'objectif final du projet, et qui ne distingue pas les causes du retard (difficulté financière réelle, litige administratif, retard technique interne).
- Aucune trace des clients dont la demande de facilité de paiement aurait été refusée n'existe dans les données disponibles : le biais de sélection (reject inference) identifié dès l'EDA (Chapitre 3) reste entier et n'a pas été corrigé.
- L'effet positif et contre-intuitif de l'ancienneté d'entreprise sur le risque du segment PM (Chapitre 3, §3.5) n'a pas encore reçu d'explication métier validée ; la variable a néanmoins été conservée dans le modèle en l'état, ce point restant ouvert.
- Le périmètre de données actuel ne couvre pas l'historique des sinistres ni les montants de prime distincts du capital assuré, qui pourraient pourtant constituer des signaux pertinents de la situation financière du client.
- Le prototype fonctionne en environnement local, sur un export statique des données, sans connexion en temps réel aux systèmes de production d'Assurance Maghrebria.

5.2 Données à Collecter à l'Avenir

La priorité de la feuille de route consiste à étendre le périmètre de données mobilisées. Il ne s'agit pas ici de générer des données artificielles, mais d'identifier précisément les sources d'information que l'entreprise pourrait collecter ou reconnecter à l'avenir pour enrichir le modèle.

Tableau 13 — Données prioritaires à collecter et leur utilité potentielle

Donnée à collecter	Utilité potentielle pour le modèle
Historique des sinistres	Mieux cerner le comportement global du client vis-à-vis de sa relation d'assurance, au-delà du seul paiement.
Montant des primes	Mesurer plus précisément l'exposition réelle du client, distincte du capital assuré.
Dates de transaction fiables	Permettre une évaluation temporelle rigoureuse du modèle (entraînement sur une période, test sur la période suivante).

Historique des facilités de paiement déjà accordées	Modéliser directement la décision métier historique (octroi, refus, incident), plutôt qu'un proxy de comportement de paiement général.
---	--

Parmi ces chantiers, la réconciliation des bases de gestion des sinistres avec les bases clients actuelles et la fiabilisation des dates de transaction (émission de quittance, encaissement effectif) directement dans les systèmes sources sont les plus structurants : ils conditionnent la capacité du projet à évoluer vers une validation temporelle robuste et vers un enrichissement significatif du pouvoir prédictif du modèle. Ces chantiers relèvent davantage d'une démarche IT et de gouvernance des données que de la data science à proprement parler, mais ils sont indispensables aux étapes suivantes.

5.3 Cadre de Gouvernance pour l'Expérimentation de Nouvelles

Variables

Au fur et à mesure que de nouvelles sources de données deviendront disponibles (cf. 5.2), il sera nécessaire de les expérimenter avant de les intégrer au modèle en production. Un cadre de gouvernance léger, inspiré des pratiques de type « Sandbox », est recommandé à cet effet, sans que cela implique la production de données synthétiques comme finalité en soi :

- Toute variable expérimentale ou pas encore validée est explicitement identifiée comme telle (par exemple via un suffixe « _SYNTHETIC » dans les jeux de test), la rendant immédiatement distinguable d'une variable réelle validée.
- Aucune variable expérimentale n'est intégrée au pipeline de production sans validation formelle de sa disponibilité réelle, de sa qualité et de son pouvoir prédictif (calcul d'IV dédié) sur un historique suffisant.
- Les expérimentations sont conduites dans un environnement isolé, avec traçabilité complète des résultats, avant toute proposition de passage en production.

Ce cadre vise avant tout à garantir qu'aucune variable non éprouvée ne puisse, même accidentellement, influencer une décision réelle d'octroi de facilité de paiement — la priorité restant la collecte effective des données décrites en 5.2, cette gouvernance n'en étant que le complément méthodologique.


Validation empirique du protocole sur données réelles

Ce cadre n'est pas resté théorique : il a été exécuté sur les deux segments, en rejouant le pipeline de production (nettoyage, binning, encodage WoE, régression logistique) sur les 10 285 clients PM et les 103 915 clients PP réels, augmentés de deux variables numériques simulées — nombre de sinistres (Binomiale Négative) et montant de sinistre (Log-Normale) — et d'une variable catégorielle simulée représentant l'historique de facilités déjà accordées. L'objectif, conformément à la règle énoncée plus haut, n'était en aucun cas d'estimer un gain de performance, mais uniquement de vérifier que le pipeline existant absorbe ces nouveaux types de variables sans modification de code.

Tableau 14 — Résultats du protocole sandbox — Segment PM vs Segment PP

Variable simulée	Taux de zéros — PM	Classes obtenues — PM	Taux de zéros — PP	Classes obtenues — PP
Nombre de sinistres (comptage)	76,2 %	2 / 5	87,8 %	1 / 5 — dégénéré
Montant de sinistre (montant)	76,2 %	2 / 5	87,8 %	1 / 5 — dégénéré
Historique de facilités (catégorielle)	—	3 modalités	—	3 modalités

Le résultat diffère nettement entre les deux segments. Sur le segment PM, le binning en 5 classes (pd.qcut) se dégrade mais reste exploitable (2 classes obtenues). Sur le segment PP, en revanche, le binning des deux variables numériques simulées échoue complètement : une seule classe est produite au lieu de cinq. La variable catégorielle, elle, est absorbée sans difficulté sur les deux segments.

*Figure 10 — Taux de zéros des variables synthétiques — PM vs PP*

i Diagnostic technique — binning dégénéré

La cause est un effet de seuil directement lié au taux de valeurs nulles : 87,8 % des clients PP simulés ont une valeur de 0 sinistre (contre 76,2 % pour PM, cohérent avec une sinistralité de base plus faible en particuliers). Le découpage en quantiles (pd.qcut, q=5) calcule ses bornes aux 0^e, 25^e, 50^e, 75^e et 100^e percentiles de la distribution ; dès que le taux de zéros dépasse 75 %, ces quatre premières bornes valent toutes 0 et sont fusionnées en une seule classe par le paramètre `duplicates='drop'`. Le WoE résultant devient une constante unique appliquée à tous les clients : la variable est techniquement absorbée par le pipeline — aucune erreur n'est levée — mais elle ne transporte plus aucune information discriminante. Ce mode de défaillance silencieux est précisément le type de risque que le protocole de sandbox est conçu pour détecter avant qu'il ne survienne sur de vraies données de sinistralité.

La solution recommandée consiste à remplacer le découpage en quantiles uniforme par un binning conditionnel pour toute variable numérique fortement zero-inflated : séparer d'abord les clients à valeur nulle (classe « 0 ») des clients à valeur strictement positive, puis n'appliquer le découpage en quantiles qu'au sous-groupe non nul. Cette adaptation, ciblée et de faible complexité, permettrait de conserver un signal exploitable y compris sur des variables à forte concentration de zéros comme la sinistralité — sans remettre en cause l'architecture générale du pipeline.

Ce résultat illustre la valeur opérationnelle du protocole : il a permis d'identifier une limite réelle et non triviale du pipeline de binning avant toute intégration de données de sinistralité effectives, alors qu'une telle défaillance silencieuse — absence d'erreur, mais absence d'information — aurait pu passer inaperçue lors d'une mise en production directe.

5.4 Vers une Mise en Production

Le passage du prototype actuel à un système en production nécessitera, au-delà des aspects techniques déjà évoqués, une validation formelle par les instances de gouvernance des risques d'Assurance Maghrebria, un raccordement aux bases de données de production (par API ou intégration directe), un hébergement sécurisé, ainsi qu'une procédure de supervision continue de la performance du modèle (suivi du drift des variables et de la stabilité du Gini dans le temps).

Conclusion Générale

Ce projet a permis de concevoir, de bout en bout, un système de scoring de crédit destiné à objectiver la décision d'octroi de facilités de paiement au sein d'Assurance Maghrebria, en s'appuyant sur des données réelles issues des segments Personnes Morales et Personnes Physiques. La démarche suivie — construction rigoureuse d'un proxy de défaut ancré sur des référentiels reconnus (Bâle III, IFRS 9), transformation des variables par Weight of Evidence, comparaison argumentée entre régression logistique et modèles d'ensemble, calibration du score par percentile — a permis d'aboutir à un outil à la fois statistiquement fondé et pleinement explicable.

Le choix assumé de privilégier la Scorecard logistique WoE à un modèle XGBoost pourtant plus performant illustre un arbitrage caractéristique des projets de data science appliqués aux secteurs régulés : la performance brute d'un modèle ne suffit pas à en justifier le déploiement si elle s'accompagne d'une perte d'explicabilité incompatible avec les exigences d'audit et de gouvernance du risque. La validation empirique de la grille de décision par percentile, par la croissance nette et monotone du taux de défaut observé d'un palier à l'autre, confirme la pertinence opérationnelle de cette approche.

Ce travail ouvre naturellement sur plusieurs perspectives d'approfondissement, détaillées au Chapitre 5 : extension du périmètre de données, validation temporelle rigoureuse, intégration de l'historique des sinistres et structuration d'un protocole Sandbox permettant d'expérimenter de nouvelles sources de signal sans compromettre l'intégrité du système en production. Au-delà de son apport technique immédiat, ce projet aura également constitué une occasion privilégiée de mettre en pratique, sur un cas d'usage réel et sensible, les exigences méthodologiques propres à la data science appliquée au risque de crédit : rigueur dans la construction de la cible, transparence sur les limites, et souci constant de l'explicabilité des décisions produites.

Bibliographie et Références

- Basel Committee on Banking Supervision, Basel III: A global regulatory framework for more resilient banks and banking systems, Bank for International Settlements.
- IFRS Foundation, IFRS 9 — Financial Instruments, International Accounting Standards Board.
- Siddiqi, N., Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring, Wiley.
- Thomas, L.C., Edelman, D.B., Crook, J.N., Credit Scoring and Its Applications, SIAM.
- Chen, T., Guestrin, C., XGBoost: A Scalable Tree Boosting System, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
- Comité Général des Assurances (CGA), Rapports annuels du secteur des assurances en Tunisie.
- Documents internes Assurance Maghrebria : Documentation Nettoyage Données Réelles, Journal des Décisions V1, Note Limites Données et Approche Recommandée, Rapport de Modélisation Données Réelles, Rapport EDA Données Réelles, Benchmark Facilité de Paiement.

Annexes

Annexe A — Extrait du Code de Calibration par Percentile

Extrait simplifié du module percentile_scoring.py assurant la conversion de la probabilité brute en score sur 10 et en palier de risque :

```
def score_client(proba, segment_code):
    percentile = _percentile_of(proba, segment_code)
    score10 = round(percentile / 10, 1)
    cutoffs = _REF['tier_cutoffs_percentile']
    if percentile <= cutoffs['faible_max']:
        tier = 'Risque faible'
    elif percentile <= cutoffs['moyen_max']:
        tier = 'Risque moyen'
    else:
        tier = 'Risque élevé'
    return score10, tier, round(percentile, 1)
```

Annexe B — Liste des Documents de Référence Internes

- Documentation_Nettoyage_Donnees_Reelles.pdf
- Journal_Decisions_V1.pdf
- Note_Limites_Donnees_Approche_Recommandee.pdf
- Benchmark_Facilite_Paiement_FR.pdf
- Rapport_Modelisation_Donnees_Reelles_1.pdf
- Rapport_EDA_Donnees_Reelles.pdf